

SPECTRA-PD

*Quantization-Induced Representation Compression
in Multimodal MRI-Genetic Models for Parkinson's Disease Detection*

Pesquisador	Antonio Matheus Monteiro
Instituição	Universidade Federal do Ceará — Departamento de Engenharia de Teleinformática
Dataset	PPMI — Parkinson's Progression Markers Initiative (Application ID: 124382)
Venue-alvo	BRACIS 2026 / CBIS 2026 / IJCNN Workshop
Ano	2026



Sumário

1.	Introdução e Motivação	3
2.	Reformulação Estratégica da Proposta	4
3.	Três Hipóteses Testáveis	5
4.	Arquitetura do Modelo	6
5.	Dataset — PPMI	7
6.	Experimentos: Análise Geométrica das Representações	8
7.	Experimentos: Robustez sob Perturbações	9
8.	Cronograma de 15 Dias	10
9.	Contribuições e Argumento Científico	11
10.	Referências e Recursos	12

1 Introdução e Motivação

A doença de Parkinson afeta mais de 10 milhões de pessoas globalmente e permanece sem cura. O diagnóstico clínico é estabelecido apenas quando 60–80% dos neurônios dopaminérgicos da substância negra já foram perdidos — eliminando a janela terapêutica mais eficaz. A detecção precoce via biomarcadores de imagem e genética é, portanto, uma prioridade de pesquisa global.

Modelos de deep learning para diagnóstico médico enfrentam dois desafios simultâneos: precisão diagnóstica e viabilidade de implantação clínica. A quantização de modelos — redução da precisão numérica de FP32 para INT8 — é a técnica mais promissora para tornar esses modelos deployáveis em ambientes reais. Porém, seu efeito sobre a geometria interna das representações aprendidas é pouco estudado, especialmente em modelos multimodais de neuroimagem.

Motivação central do SPECTRA-PD

O projeto investiga como o Quantization-Aware Training (QAT) altera a geometria e a estabilidade das representações multimodais aprendidas por modelos de neuroimagem para Parkinson — combinando RM T1 dos gânglios da base com dados genéticos SNP como modalidade complementar. A pergunta não é 'o modelo classifica melhor', mas 'o que acontece com o espaço de representação sob quantização?'

Essa reformulação é estrategicamente importante: em vez de afirmar descoberta de biomarcadores — o que exige validação biológica extensiva — o SPECTRA-PD afirma algo mensurável, robusto e difícil de derrubar: que QAT produz representações mais compactas e estáveis sem perda significativa de desempenho diagnóstico. Essa é uma contribuição perfeitamente publicável em congresso.

A proposta original apresentava três afirmações simultâneas ao revisor: (1) RM + SNP melhora classificação de Parkinson; (2) QAT funciona como regularizador espectral; (3) existe relação neurobiológica entre SNPs e regiões destacadas pelo modelo. Para um paper de 6–8 páginas, isso é cientificamente arriscado.

Dimensão	Versão original (risco alto)	Versão SPECTRA-PD (risco baixo)
Pergunta central	QAT enfatiza features biologicamente relevantes correlacionadas com SNPs?	Como QAT altera a geometria e estabilidade das representações multimodais?
O que os SNPs são	Evidência biológica da hipótese	Modalidade complementar (sem dependência causal)
O que se precisa provar	Causalidade biológica (muito difícil)	Métricas geométricas (mensurável e direto)
Vulnerabilidade ao revisor	Alta — "não há prova de biomarcadores"	Baixa — métricas objetivas e reproduzíveis
Título	"QAT como regularizador espectral em RM + genética"	"Quantization-Induced Representation Compression..."

O que foi removido completamente: correlação Grad-CAM $\leftrightarrow$ SNP, associação causal genética, afirmações de que "QAT destaca regiões biologicamente relevantes" e "QAT descobre sinais precoces". Essas eram as partes mais vulneráveis à rejeição.

H1**QAT reduz a complexidade espectral das representações internas**

Descrição

Métricas: Effective Rank (Roy & Vetterli, 2007) e Spectral Entropy sobre a distribuição dos singular values das ativações da penúltima camada. Expectativa: $ER(QAT) < ER(FP32)$ e $SE(QAT) < SE(FP32)$, indicando representações mais compactas e de menor rank intrínseco.

Justificativa

ER e SE mensuráveis diretamente. Não requer interpretação biológica.

H2**QAT aumenta a estabilidade das representações sob perturbações**

Descrição

Três testes: (a) ruído gaussiano na RM com $\sigma \in \{0, 0.01, 0.05, 0.1\}$; (b) dropout de SNPs com taxa $\in \{0\%, 25\%, 50\%, 75\%\}$; (c) perturbação adversária leve via FGSM com $\epsilon \in \{0, 0.01, 0.03\}$. Expectativa: QAT degrada menos que FP32 sob as mesmas perturbações.

Justificativa

Teste empírico direto. Se QAT degradar menos, resultado forte e publicável.

H3**QAT preserva desempenho diagnóstico apesar da compressão**

Descrição

Métricas: AUC-ROC, F1-score e Matthews Correlation Coefficient (MCC) — MCC é mais robusto a desbalanceamento que acurácia e F1 isolados. Expectativa: diferença de AUC entre FP32 e QAT $< 2\%$, com ganho de 4× em tamanho e 3× em latência.

Justificativa

Valida viabilidade de deploy clínico. Complementa H1 e H2.

Princípio arquitetural

A arquitetura permanece idêntica à versão original — o que muda é a interpretação científica do papel dos SNPs: de 'evidência biológica' para 'modalidade complementar'. Isso reduz o risco de rejeição sem alterar uma linha de código.




Figura 1: Pipeline SPECTRA-PD. Os SNPs são modalidade complementar, não evidência causal da hipótese.

5 Dataset — PPMI

Todos os dados utilizados são públicos, provenientes do PPMI — Parkinson's Progression Markers Initiative, com acesso aprovado (Application ID 124382).

Parâmetro	Valor
Sujeitos PD	323
Controles HC	108
Total	431 sujeitos
Ratio PD:HC	3:1 — tratado com pos_weight=3.0 na BCEWithLogitsLoss
Scanner	Siemens 3T (Prisma, Prisma Fit, Skyra, Vida)
Sequência RM	T1 MPRAGE sagital, 1mm isotrópico, Baseline
Pré-processamento	ANTsPy: N4 bias correction + skull strip + MNI152 Affine
ROIs extraídas	CIT168 Atlas: putâmen, caudado, globo pálido, tálamo (32 ³ cada)
Genotipagem	NeuroX Array — Project 107 PPMI (PLINK format, 2018)
SNPs incluídos	rs356181, rs2736990 (SNCA) · rs2230288 (GBA) · rs35801418 (LRRK2) · rs213202 (VPS52)
Validação	5-fold cross-validation estratificado por diagnóstico
Harmonização	neuroCombat para remoção de batch effects entre 33 sites

O experimento central compara quatro modelos em duas dimensões: desempenho diagnóstico e geometria das representações latentes. Essa é a tabela principal do paper:

Métrica	FP32 Image-only	FP32 Multimodal	PTQ INT8	QAT INT8
AUC-ROC ↑	—	—	—	—
F1-Score ↑	—	—	—	—
MCC ↑	—	—	—	—
Effective Rank ↓	—	—	—	—
Spectral Entropy ↓	—	—	—	—
Mutual Info (vs FP32)	ref	—	—	—
Tamanho (MB) ↓	—	—	—	—
Latência (ms) ↓	—	—	—	—

Tabela 1: Os valores serão preenchidos com os resultados experimentais. Coluna QAT destacada — é o objeto central da análise.

Definições formais das métricas geométricas:

Effective Rank (ER): $ER(F) = \exp(H(p))$ onde $H(p) = -\sum p_i \log(p_i)$ é a entropia de Shannon sobre a distribuição normalizada dos singular values de F . ER mede o número efetivo de dimensões ativas na representação.

Spectral Entropy (SE): $SE(F) = -\sum p_i \log(p_i)$ com $p_i = \sigma_i^2 / \sum \sigma_i^2$. SE alta → energia distribuída por muitos componentes (representação difusa). SE baixa → energia concentrada em poucos componentes (representação compacta).

Mutual Information (MI): Estimativa via histograma 2D entre representações de FP32 e QAT. MI alta → QAT preserva informação diagnóstica do modelo original.

O experimento de robustez é o que mais diferencia o SPECTRA-PD de um classificador convencional. Se QAT degradar menos que FP32 sob perturbações, o resultado é forte e publicável independentemente do resultado de H1.

Teste	Perturbação	Parâmetros	Métrica
Ruído na RM	Ruído gaussiano aditivo nos voxels das ROIs	$\sigma \in \{0, 0.01, 0.05, 0.1\}$	AUC por nível de σ
SNP Dropout	Mascaramento aleatório das features genéticas	Taxa $\in \{0\%, 25\%, 50\%, 75\%\}$	AUC por taxa de mascaramento
FGSM Adversarial	Perturbação adversária no gradiente da RM	$\epsilon \in \{0, 0.01, 0.03\}$	AUC por ϵ

Argumento científico da robustez

Se QAT reduz a complexidade espectral (H1), as representações de menor rank efetivo devem ser naturalmente mais estáveis — há menos componentes para serem corrompidos por ruído ou perturbação. H2 é, portanto, uma consequência teoricamente motivada de H1, não uma hipótese independente. Isso fortalece a narrativa do paper: as três hipóteses são logicamente encadeadas.

Os resultados de robustez serão apresentados como curvas de degradação de AUC em função do nível de perturbação — uma curva por modelo (FP32, PTQ, QAT). A área sob a curva de degradação (quanto o modelo resiste) é a métrica comparativa principal.

Dias	Tarefa	Entrega
1–2	Download + pré-processamento ANTs (skull strip, N4IT1) normalizados	Volume 152
3	Extração de ROIs via CIT168 Atlas	Arrays .npy 4×32×32×32 por sujeito
3	QC genético + conversão PLINK → .raw → snp_5k	5k SNPs normalizados
4–5	Treino FP32 image-only (baseline)	Modelo + curvas de convergência
5–6	Treino FP32 multimodal (CNN + SNP)	Comparação de AUC com baseline
7	PTQ INT8	Modelo quantizado + tabela perf/latência
8–9	QAT INT8 (retreino com fake quantizers)	Modelo QAT + curvas de QAT
10	H1: Effective Rank + Spectral Entropy + MI	Tabela geométrica completa
11	H2: Robustez (ruído, SNP dropout, FGSM)	Curvas de degradação de AUC
12–13	Escrita do artigo (6–8 páginas)	Draft completo
14–15	Revisão + submissão	Paper submetido

Argumento central do paper (em vez de):

■ Versão fraca (não usar)	■ Versão SPECTRA-PD
"QAT encontra biomarcadores de Parkinson"	"QAT produz representações mais compactas e robustas"
"A rede aprende regiões biologicamente relevantes"	"A geometria do espaço latente muda de forma mensurável com QAT"
"SNPs confirmam os achados de neuroimagem"	"SNPs são modalidade complementar que enriquece a representação"
Exige validação biológica (meses/anos de trabalho)	Verificável com as ferramentas do próprio pipeline

C1 — Classificador multimodal leve

CNN 3D (ROIs gânglios) + MLP SNP com menos de 2M parâmetros. FP32 image-only como baseline + FP32 multimodal como ablação.

C2 — Análise geométrica sob quantização

Primeira comparação sistemática de Effective Rank e Spectral Entropy entre FP32, PTQ e QAT em modelos de fusão RM + genética para Parkinson.

C3 — Benchmark de robustez multimodal

Curvas de degradação de AUC sob ruído, SNP dropout e FGSM para os quatro regimes — resultado publicável independente da direção de H1.

C4 — Modelo INT8 deployável

Modelo QAT com latência < 50ms e tamanho < 10MB para ambientes clínicos com recursos computacionais limitados.

Dataset	PPMI — ppmi-info.org Application ID: 124382
Atlas	CIT168 Basal Ganglia Atlas — osf.io/jkzwp
Genética	Project 107: NeuroX SNP — PPMI Genetic Data, PLINK 2018
Framework	PyTorch 2.2 + torch.ao.quantization
Pré-proc.	ANTsPy — github.com/ANTsX/ANTsPy
PLINK2	cog-genomics.org/plink/2.0
Harmoniz.	neuroCombat — github.com/Jfortin1/neuroCombat
ER Métrica	Roy & Vetterli (2007). The effective rank: A measure of effective dimensionality. EUSIPCO.
QAT Ref.	Jacob et al. (2018). Quantization and Training of Neural Networks. CVPR.
QAT Reg.	Bhatt et al. (2024). Quantization as Regularization. NeurIPS Workshop.
RACF	Liu et al. (2025). Cross-modal Attention Fusion for Multimodal PD Detection. arXiv.
Venue	BRACIS 2026 · CBIS 2026 · IJCNN Workshop · SBCAS 2026

SPECTRA-PD — Quantization-Induced Representation Compression in Multimodal MRI-Genetic Models for Parkinson's Disease Detection
Antonio Matheus Monteiro · UFC Virtual · Fortaleza, CE · 2026